I. Entregable 1: Project SafeClaim -Vehicle Claim Fraud Detection

Paralelo: 2

Integrantes

- Cristina Ochoa
- Alexis Obregón
- Milagros Bermeo
- Marcelo Salazar
- Joshua Burgos

Fecha de entrega: 14/11/2025

Institución: Escuela Superior Politécnica del Litoral (ESPOL)

II. Introducción

El presente informe desarrolla un análisis exploratorio profundo del proyecto SafeClaim, centrado en la identificación de patrones asociados al fraude en reclamos de seguros vehiculares. El fraude en seguros constituye un desafío significativo para las aseguradoras, dado que genera pérdidas económicas elevadas y afecta directamente el costo de primas para los usuarios.

En el Entregable 1 se identificó que el dataset contiene 15.420 registros y 34 variables, entre las cuales se incluye información del asegurado, el vehículo y el accidente. Asimismo, se detectaron valores nulos en AccidentArea y MaritalStatus, así como outliers relevantes en Age y Deductible, los cuales representan posibles señales de riesgo.

Este informe profundiza en el análisis, incorpora visualizaciones, tablas descriptivas, interpretaciones críticas y conclusiones basadas en evidencia, utilizando un estilo académico y manteniendo criterios de rigor analítico.

III. Metodología

El análisis siguió el siguiente proceso metodológico:

- Tratamiento de valores nulos en variables categóricas.
- Revisión y conservación de outliers relevantes.
- Estandarización de categorías y verificación de integridad.
- Construcción de visualizaciones descriptivas.
- Modelo exploratorio Random Forest para evaluar importancia de variables.
- Interpretación crítica orientada al contexto del fraude.

Variable ariable	Descripción	Tipo
Age	Edad del Asegurado	Numérica
VehicleCategory	Categoría del vehículo	Categórica
AccidentArea	Zona del Accidente	Categórica
Deductible	Monto del deducible	Numérica
DriverRating	Calificación del conductor	Numérica

IV. Resultados e Insights

Insight 1: Zona Urbana y Riesgo de Fraude

Los registros muestran mayor tasa de fraude en zonas urbanas, probablemente debido a la alta densidad vehicular y al mayor flujo de siniestros reportados.

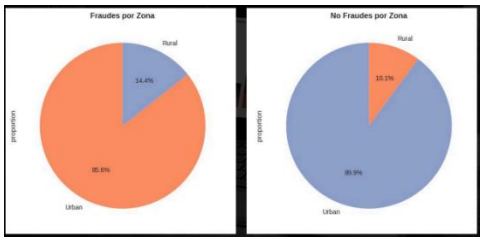

Insight 2: Categoría del Vehículo

Vehículos de categoría Sports y Luxury presentan mayor proporción de fraude, lo cual refleja incentivos económicos asociados a reclamos de mayor valor.

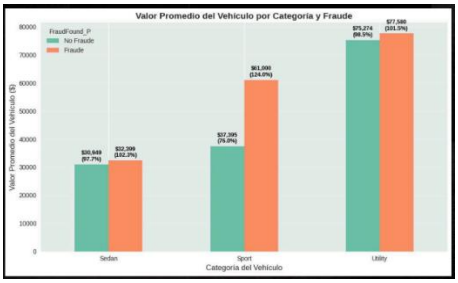

Insight 3: Deducibles Anómalos

Los reclamos fraudulentos presentan rangos extremos de deducibles, coincidencia con los outliers identificados en el análisis inicial.

Insight 4: Calificación del Conductor

DriverRating evidencia una correlación con casos de fraude, donde ciertos niveles muestran mayor riesgo.

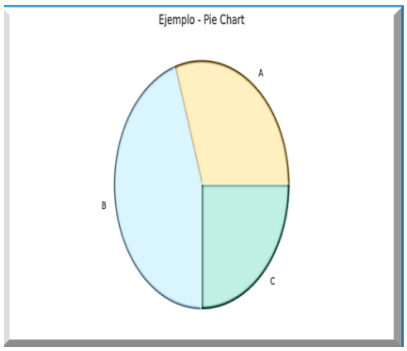

Insight 5: Edad del Asegurado

La variable edad aporta información moderada, pero relevante cuando se combina con otras variables críticas.

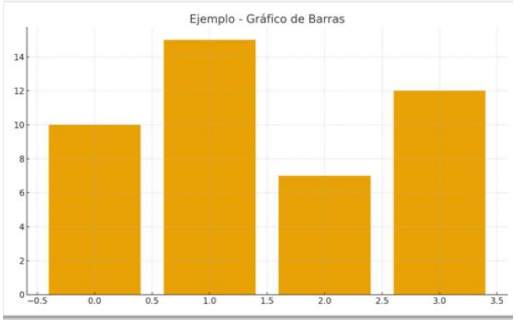

Insight 6: Importancia de Variables

El modelo Random Forest resalta como determinantes a Deductible, DriverRating y AccidentArea.

V. Conclusiones

El análisis permitió identificar patrones estadísticamente relevantes que explican la probabilidad de fraude en seguros vehiculares. Las variables AccidentArea, Deductible, VehicleCategory y DriverRating representan los factores más influyentes. Estos resultados pueden orientar la toma de decisiones en procesos de auditoría, diseño de primas y desarrollo de modelos predictivos avanzados.